空间转录组学入门

从细胞、DNA 和蛋白质到 CS 数据与科研问题

面向计算机与人工智能专业的本科生和研究生

适用读者：有计算机或人工智能背景，但对生物学基本概念尚不熟悉的学生。本文从你能想象的组织和细胞出发，逐步说明 RNA 怎样变成实验数据，再解释算法能用这些数据研究什么。不要求预先学过分子生物学；读到矩阵部分时，具备基本的线性代数和机器学习概念会有帮助。

写作动机：我的研究生学习领域涉及空间转录组学相关知识。在学习和研究过程中，我体会到，刚接触这一方向的同学往往需要先熟悉一些生物学概念，才能进一步理解实验数据和计算方法。因此，我整理了这份入门资料，希望把相关知识讲得更清楚一些，也帮助更多同学顺利迈出第一步。

读完后，你应该能够用自己的话说明：空间转录组测什么、为什么要保留位置、矩阵的一行和一列代表什么，以及一个 AI 模型的输出如何成为有依据的科学结论。

先给脑中放一张简单的图

一小块组织里有许多细胞。研究人员测量不同位置的 RNA，用这些分子信号了解细胞的身份和状态，再把信息放回组织地图。这就是后面所有内容的起点。RNA 是什么、为什么能提供线索，我们接下来慢慢解释。

阶段	阅读内容	理解目标
先认识研究对象	第 1–5 章	细胞、DNA、基因、RNA、蛋白质和表达
再理解测量方法	第 6–9 章	转录组、单细胞、空间信息与实验读数
最后进入 CS 与科研	第 10–15 章	数据表示、分析流程、研究问题和验证
遇到术语时回查	第 16–17 章	核心名词及来源

贯穿全文的例子

我们假设研究人员拿到一张肿瘤组织薄片，想了解“不同细胞在哪里，以及免疫细胞是否出现在肿瘤内部”。这是一个研究问题示例，不预设答案，也不凭细胞分布直接判断治疗效果。后面的计数和布局均为教学构造。

你不需要一次读完。前五章能讲清楚，就已经补上了理解空间转录组最关键的基础。类比帮助建立直觉，但不能代替真实的分子与实验过程。

整理说明：本讲义依据《空间转录组学 _CS_AI 入门》PDF 整理，保留原文的章节顺序、讲解方式与教学例子，仅补充少量面向 CS / AI 读者的符号解释与阅读提示。原文注明的资料核对日期为 2026 年 10 月 14 日；文末来源沿用原文，不表示本次对所有在线页面作了重新核验。

目录

第一部分 生物学基础 5

1 先认识组织和细胞 6
1.1 组织和细胞分别在哪一层 . . . 6
1.2 细胞可以想象成一个微小的工作单位 . . . 6
1.3 为什么显微镜照片还不够 . . . 7

2 DNA 和基因究竟是什么 8
2.1 DNA 是保存遗传信息的分子 . . . 8
2.2 基因是 DNA 上具有功能的一段信息 . . . 8
2.3 染色体和基因组怎么放进这张图 . . . 8
2.4 为什么不同细胞可以拥有相似 DNA . . . 9

3 RNA 是怎样产生的 10
3.1 细胞会按照 DNA 信息制造 RNA . . . 10
3.2 mRNA 是 RNA 中的一种 . . . 10
3.3 RNA 为什么能提供细胞状态的线索 . . . 10
3.4 先把一个常见误解排除 . . . 10

4 蛋白质是什么以及怎样产生 12
4.1 蛋白质由氨基酸链组成 . . . 12
4.2 翻译把 mRNA 的信息用于制造蛋白质 . . . 12
4.3 为什么蛋白质重要 . . . 12

5 基因表达是在说什么 14
5.1 表达表示基因信息被用于产生功能产物 . . . 14
5.2 为什么相似 DNA 能产生不同细胞 . . . 14
5.3 细胞类型和细胞状态要分开 . . . 14
5.4 标志基因怎样帮助识别细胞 . . . 14
5.5 RNA 多为什么不一定等于蛋白质多 . . . 14

第二部分 测量原理与空间信息 15

6 转录组是很多 RNA 的整体情况 16
6.1 先理解为什么要加一个“组”字 . . . 16
6.2 一个基因和一个 RNA 分子不是一一对应 . . . 16
6.3 测转录组不等于测到了所有 RNA . . . 16
6.4 RNA 测量怎样帮助研究组织 . . . 16

Auutuumn

7 混在一起测和分开测有什么区别 17
7.1 第一种方式是测一份混合组织 . . . 17
7.2 第二种方式是尽量分别测每个细胞 . . . 17
7.3 单细胞核又是什么 . . . 17
7.4 我们的研究问题还缺什么 . . . 17

8 空间转录组把表达放回组织地图 18
8.1 空间转录组同时关联表达和位置 . . . 18
8.2 为什么位置有生物学意义 . . . 18
8.3 空间不意味着每一行都是一个细胞 . . . 18

9 实验怎样知道哪些 RNA 来自哪里 19
9.1 先看一种典型的测序路线 . . . 19
9.2 一份读数要回答两个问题 . . . 19
9.3 为什么多个 reads 不一定等于多个 RNA . . . 19
9.4 另一条路线是直接在组织里成像 . . . 19

第三部分 计算分析与科研实践 20

10 从 RNA 读数到 CS 的矩阵 21
10.1 把同一位置、同一基因的信号汇总 . . . 21
10.2 一行、一列、一个数字各是什么 . . . 21
10.3 这样就能开始读表达模式 . . . 21
10.4 矩阵里的零该怎样理解 . . . 21

11 坐标、图像和文件怎样与矩阵对应 22
11.1 表达矩阵之外还要有坐标 . . . 22
11.2 表达相似和位置相邻是两种关系 . . . 22
11.3 组织图像是第三类信息 . . . 22
11.4 AnnData 和 H5AD 只是数据容器与格式 . . . 22

12 常见分析步骤分别为了什么 23
12.1 首先确认你拿到的是可靠输入 . . . 23
12.2 再处理数值尺度并找到表达模式 . . . 23
12.3 聚类是发现群体，注释是解释群体 . . . 23
12.4 为什么 UMAP 图不是组织地图 . . . 23

13 算法能够研究哪些问题 24
13.1 问题一：组织里有哪些不同区域 . . . 24
13.2 问题二：混合区域里有什么细胞 . . . 24

Auutuumn

13.3 问题三：能否从图像预测表达 24
13.4 问题四：哪些信号在空间上变化 24
13.5 问题五：哪些细胞可能相互影响 24

14 用一个问题串起科研全过程 25
14.1 从问题开始，而不是从模型开始 25
14.2 第一步：分清观察与推断 25
14.3 第二步：定义你要比较的区域 25
14.4 第三步：选择与测量单位相符的方法 25
14.5 第四步：看结果是否真的支持描述 25
14.6 第五步：决定能把结论说到哪里 25

15 从 CS 模型到可信科学结论 26
15.1 大量位置不等于大量独立患者 26
15.2 训练、测试怎样分，取决于想验证什么 26
15.3 已有算法结果未必就是地面真值 26
15.4 差异表达不直接证明原因 26
15.5 读论文时先回答五个问题 26

第四部分 术语回查与延伸阅读 27

16 核心术语回查 28
16.1 如何使用这份术语表 28
16.2 核心术语与常见混淆 28

17 来源和下一步阅读 29
17.1 按学习进度安排下一步阅读 29
17.2 参考来源 29

Auutuumn

第一部分

生物学基础

第 1–5 章：从组织和细胞到基因表达

这一部分要理解什么

先认识研究对象，再认识细胞如何保存和使用信息。建立 DNA、基因、RNA、蛋白质与表达之间的联系，区分细胞类型和细胞状态，为理解实验读数做好准备。

Auutuumn

1 先认识组织和细胞

想象医生取出一小块组织，把它切成薄片，放在显微镜下。这张薄片并不是均匀的一团材料：里面有许多细胞，细胞之间还有支撑它们的物质。我们研究的“组织”，就是这样的结构。

1.1 组织和细胞分别在哪一层

层次	简单解释	例子
人体	整个生命个体	一个人
器官	多种组织共同承担一定功能的结构	心脏
组织	细胞与周围材料形成的结构	心脏中的心肌组织
细胞	人体结构和功能的基本单位	心肌细胞

所以，你可以先记住“人体 → 器官 → 组织 → 细胞”。组织比细胞大，但组织不仅仅是细胞的简单堆积，细胞之间的材料和排列也属于组织的一部分。[1]

1.2 细胞可以想象成一个微小的工作单位

典型有核人体细胞外面有细胞膜，内部有细胞质和细胞核。细胞膜像边界；细胞质是内部许多活动发生的环境；细胞核保存着大部分 DNA。这里描述的是常见结构，人体也有成熟红细胞等例外，不需要用例外打断最初的理解。

细胞有不同分工。例如，上皮细胞构成身体表面或器官内壁等结构；免疫细胞参与防御；成纤维细胞参与组织支撑和修复。先认识这三类名字就够了，不必现在背全部细胞分类。

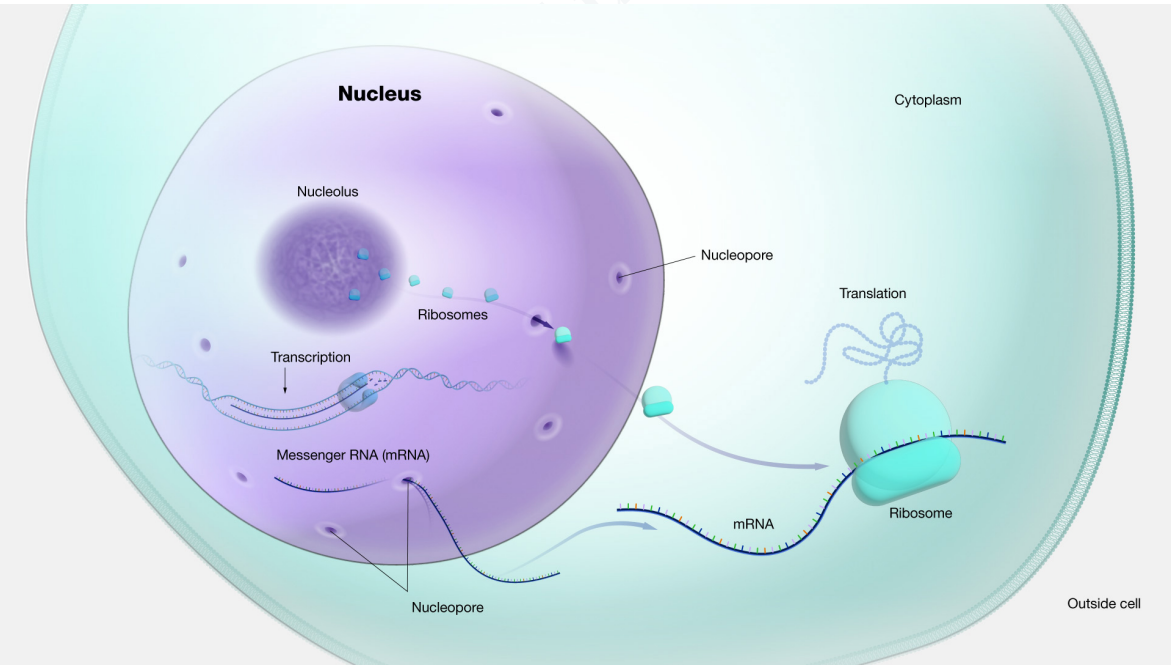
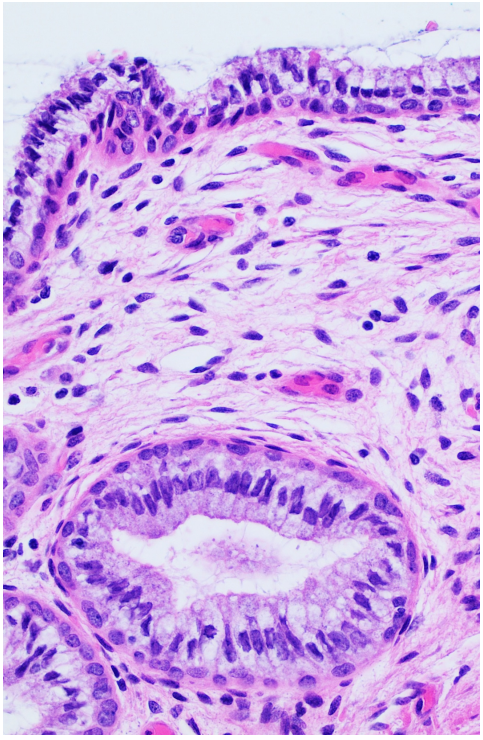


图 1 典型有核细胞的局部示意。紫色区域为细胞核（Nucleus），其外为细胞质（Cytoplasm），最外侧为细胞膜；核糖体参与蛋白质合成。先认识这些位置关系，图中的转录与翻译将在后文展开。示意颜色与尺寸用于教学，不是显微照片。

图片：NHGRI；许可：Public domain；原图等比缩放。

1.3 为什么显微镜照片还不够

照片能提供外形、排列和组织结构的线索，专家也能据此作出许多判断。但它不能直接给出所有细胞的分子状态。我们希望知道某个细胞是否在增殖、是否受到刺激，以及它属于哪类细胞；这时需要更多测量。



先看组织的排列。深紫色区域帮助观察细胞核的位置，图中还能看到表面上皮和下方的腺体结构。

再区分形态与分子测量。组织照片有助于认识结构；若要知道哪些基因在这些位置表达，还需要相应的分子测量。

图 2 真实的宫颈管组织显微图像，采用苏木精—伊红（H&E）染色。它展示了形态与排列，但不能直接给出各位置的 RNA 表达；此图不是贯穿全文肿瘤案例的样本。

图片：Mikael Häggström；许可：CC0 1.0；原图等比缩放。

回到肿瘤薄片：我们能看到一片组织，但还想知道其中哪些位置有免疫细胞。这就要进一步认识细胞里面保存和使用的信息。

本章要记住

组织里有细胞；细胞有不同分工；照片提供形态，分子测量提供另一类信息。

2 DNA 和基因究竟是什么

2.1 DNA 是保存遗传信息的分子

DNA 是一种实际存在的分子，不是抽象概念。它的结构常画成双螺旋，像扭转的梯子。DNA 的序列可用 A、T、C、G 四种字母表示；这些字母代表不同的碱基，它们的排列承载遗传信息。[2]

作为 CS 学生，你可以把 DNA 序列先看成很长的字符串。但真实 DNA 是分子，它的包装方式和细胞中的环境也会影响信息如何被使用。字符串只是第一层表示。

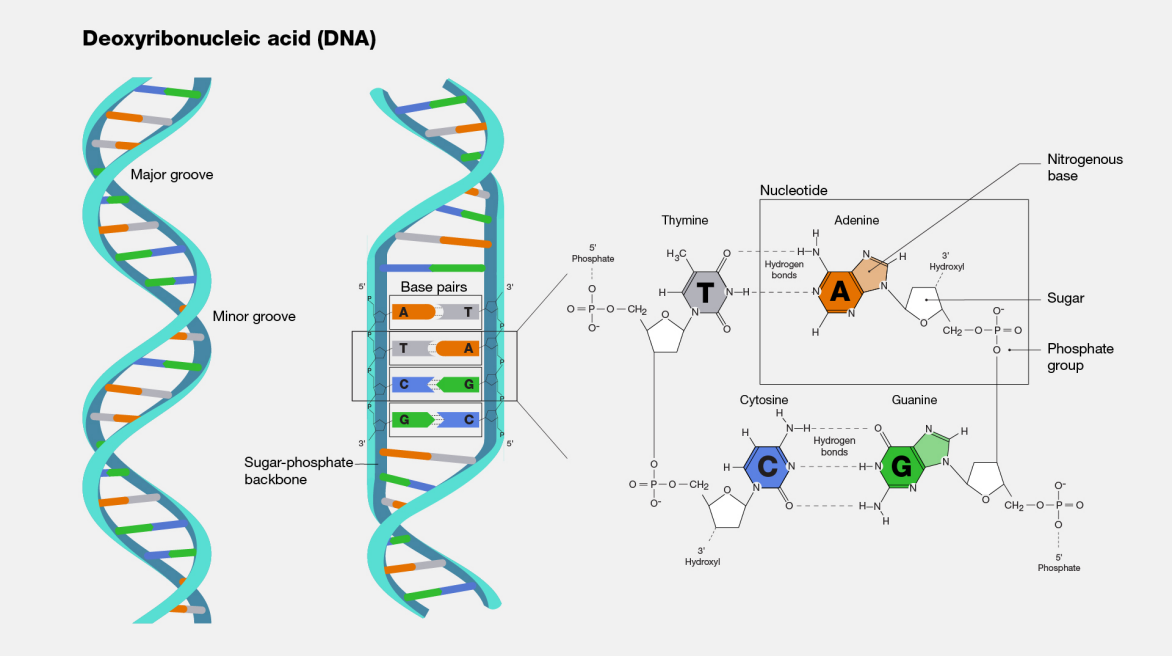


图 3 DNA 的结构与序列是两个观察视角。左侧为双螺旋，中间放大了碱基配对，右侧显示局部化学结构；A 与 T 配对，C 与 G 配对。入门时重点理解分子结构与字母序列的联系，无须记忆右侧化学细节。

图片：NHGRI；许可：Public domain；原图等比缩放。

2.2 基因是 DNA 上具有功能的一段信息

基因不是整条 DNA 的另一个名字。一个基因对应 DNA 上的特定区段，可用于产生 RNA；许多基因最终与蛋白质的制造有关，还有一些基因产生的 RNA 本身就有功能。[3]

把 DNA 类比成一本很长的说明书，基因像其中一段有具体用途的内容。DNA 上也有参与调控等作用的区域，因此不能把全部 DNA 都当成一段段蛋白质制造说明。

2.3 染色体和基因组怎么放进这张图

DNA 会与蛋白质结合，组织成染色体。可以粗略把染色体理解成 DNA 的包装形式。基因组指一套遗传信息；它与“此刻表达了什么”是两个问题。[3]

概念	你可以先这样记	不要混淆成
DNA	保存遗传信息的分子	某一个基因
基因 Gene	DNA 上具有功能的特定区段	整套遗传信息
染色体 Chromosome	DNA 与蛋白质形成的组织结构	新的另一种信息分子
基因组 Genome	一套遗传信息	当前正在使用的信息集合

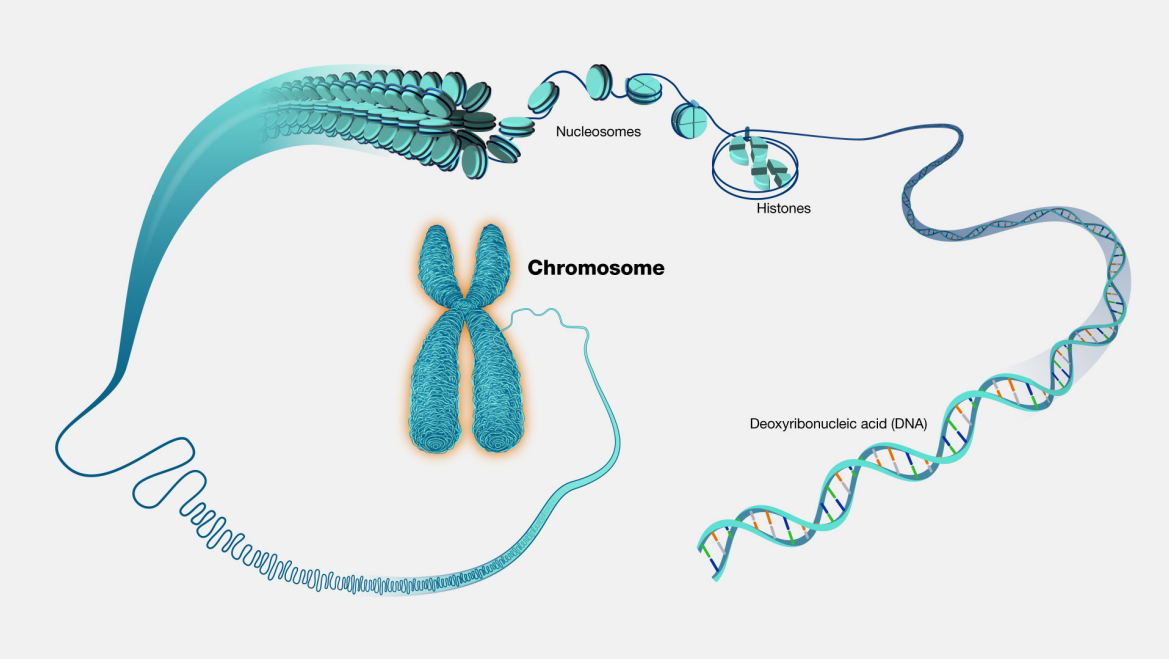


图 4 从 DNA 双螺旋到染色体的组织层次。可从右向左观察 DNA 如何与蛋白质结合并形成更高层次的包装；各部分不按统一比例绘制。图中的 X 形是特定阶段的结构示意，不表示染色体始终呈 X 形。

图片：NHGRI；许可：Public domain；原图等比缩放。

2.4 为什么不同细胞可以拥有相似 DNA

同一个人的多数有核体细胞，基因组大体相同。然而神经细胞和免疫细胞的工作明显不同。重要原因之一是：它们使用不同的基因，使用程度也不同。DNA 中“有这段信息”与细胞“现在正在使用这段信息”，需要分开。

本章要记住

基因是 DNA 的特定区段；基因存在，不代表它此刻被同样程度地使用。

3 RNA 是怎样产生的

3.1 细胞会按照 DNA 信息制造 RNA

RNA 是另一类实际存在的分子。细胞按照 DNA 中的信息合成 RNA，这个过程叫**转录**（transcription）。DNA 并不是整条变成 RNA；细胞利用相应信息生成 RNA 分子，DNA 仍然存在。[4]

继续用说明书类比：DNA 是保存的信息，RNA 可以像为当前工作制作的副本。一段基因信息可以对应多个 RNA 分子，所以 RNA 的数量会随细胞状态变化。这里的“副本”强调信息关系，不表示 DNA 和 RNA 的化学组成完全相同。

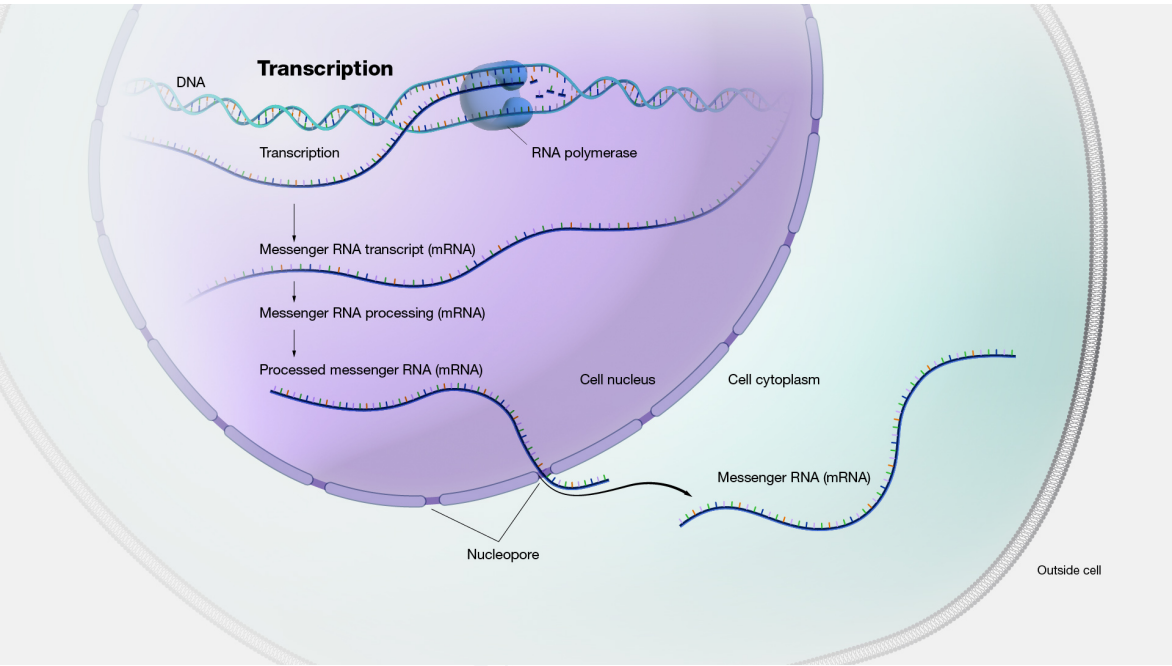


图 5 真核细胞中的转录及 mRNA 加工示意。沿图自上而下观察：RNA 聚合酶根据 DNA 模板合成 RNA，mRNA 经加工后可经核孔离开细胞核。此图展示 mRNA 的典型路线，不表示所有 RNA 都会离核或进入翻译。

图片：NHGRI；许可：Public domain；原图等比缩放。

3.2 mRNA 是 RNA 中的一种

mRNA 叫信使 RNA，它携带用于制造蛋白质的信息。RNA 还有其他类别，其中一些参与蛋白质制造的过程，另一些参与调控等功能。你现在只需记住：**mRNA 是 RNA 的一个子类，不是所有 RNA 都是 mRNA**。[5]

3.3 RNA 为什么能提供细胞状态的线索

如果某类 RNA 在一个细胞中测得比较多，说明这个细胞在相应表达方面有一定信号。不同细胞会呈现不同的 RNA 组合；同一类细胞受到刺激后，组合也可能改变。通过这些组合，我们可以研究细胞的身份和状态。

但 RNA 水平不是“此刻产生速度”的直接读数。它同时受合成、降解及测量过程影响。我们测到的是实验所记录的 RNA 信号，再据此作解释。

3.4 先把一个常见误解排除

“DNA → RNA”表示信息通过转录被用于制造 RNA，不表示细胞把自己的 DNA 消耗掉。类似你从文件生成多个工作副本，原文件仍然在，只是这个计算机类比忽略了许多真实分子过程。

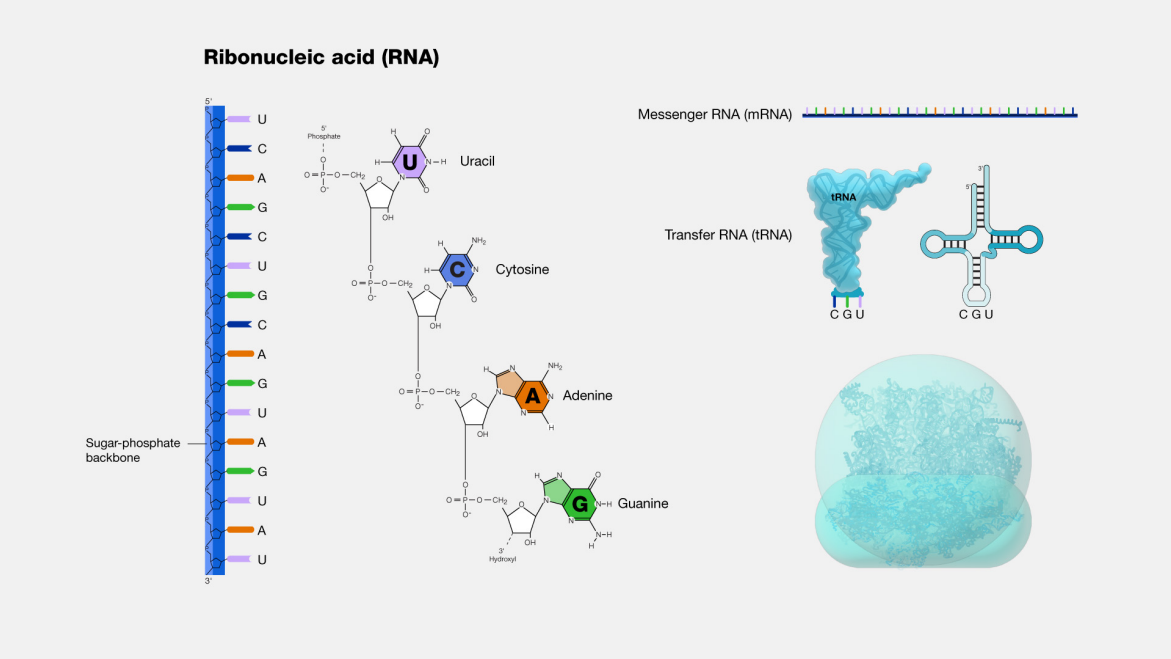


图 6 RNA 不只有 mRNA。右上方为信使 RNA（mRNA），其下展示转运 RNA（tRNA）和核糖体 RNA（rRNA）相关结构；后两者也参与蛋白质合成。RNA 可以形成复杂结构，不能把所有 RNA 都理解为等待翻译的一条直线。

图片：NHGRI；许可：Public domain；原图等比缩放。

你想知道什么	更相关的观察
细胞拥有哪些遗传信息	DNA 或基因组信息
细胞当时有哪些 RNA 信号	RNA 或转录组信息
细胞里有哪些功能性蛋白质	蛋白质相关测量

回到我们的薄片：测 RNA 可以帮助识别免疫相关的表达特征，但并不是直接拍到了一个“免疫细胞标签”。我们后面还会解释怎样从信号推断身份。

本章要记住

转录根据 DNA 信息产生 RNA；测得的 RNA 水平为细胞身份和状态提供线索。

4 蛋白质是什么以及怎样产生

4.1 蛋白质由氨基酸链组成

蛋白质是一类分子，通常由一条或多条氨基酸链构成。把氨基酸想成不同种类的小珠子：珠子按一定顺序连起来，链再折叠成一定形状。顺序影响结构，结构与功能密切相关。[6]

单个蛋白质分子在分子尺度，肉眼看不见，普通光学显微镜通常也无法直接辨认其具体形状。但大量蛋白质构成的材料可以看见、摸到：头发富含角蛋白，肌肉含有参与收缩的蛋白质。蛋清也含有许多蛋白质，同时含大量水。

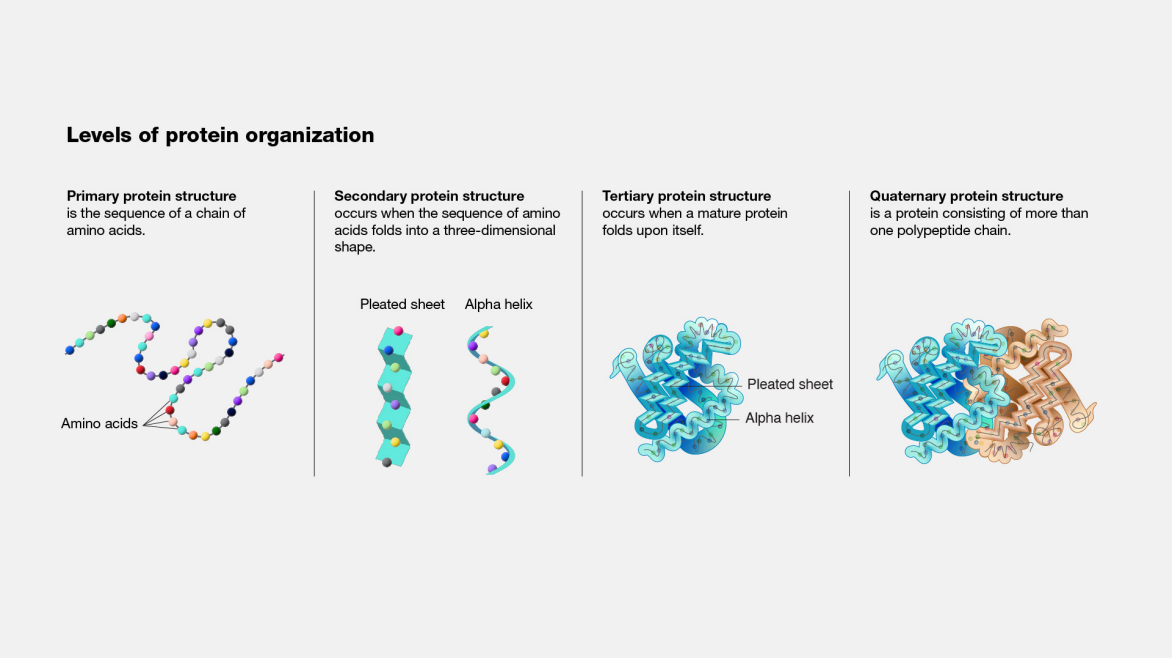


图 7 蛋白质的结构层次。从左到右依次为氨基酸序列、局部结构、整体折叠与多链组装；并非每种蛋白质都有多链组装这一层次。先理解“链具有顺序，也具有空间结构”，再将结构与功能联系起来。

图片：NHGRI；许可：Public domain；原图等比缩放。

4.2 翻译把 mRNA 的信息用于制造蛋白质

细胞中的核糖体等分子机器读取 mRNA 的信息，将氨基酸按相应顺序连接起来。这个过程叫**翻译**（translation）。这里的“翻译”是分子生物学术语，和自然语言翻译是不同任务。[7]

4.3 为什么蛋白质重要

许多具体工作由蛋白质承担：酶帮助化学反应进行，血红蛋白运输氧气，抗体参与防御，受体接收信号。受体可以先理解为细胞识别某些外来分子信号的组件。

本章要记住

DNA 保存信息；转录产生 RNA；其中的 mRNA 可被翻译成蛋白质；蛋白质承担许多实际功能。

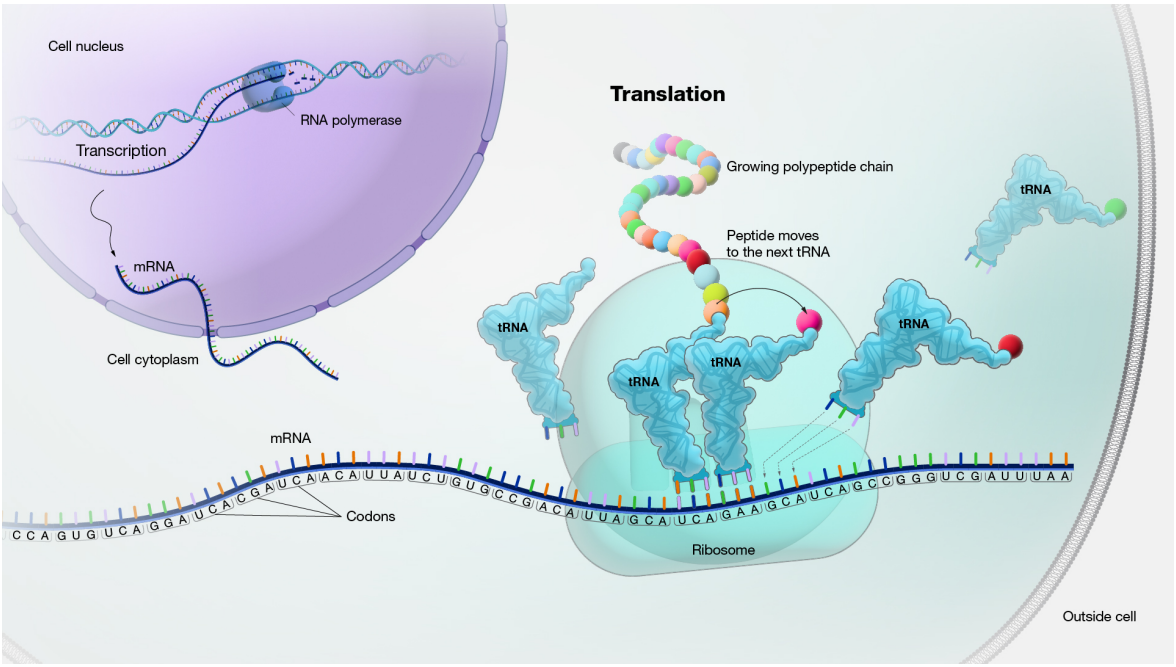


图 8 翻译过程示意。下方长链为 mRNA，蓝绿色结构为核糖体，正在延长的彩色小球串代表多肽链；tRNA 参与运送相应的氨基酸。RNA 提供编码信息，氨基酸构成多肽链，不能把翻译理解为 RNA 本身变成蛋白质。

图片：NHGRI；许可：Public domain；原图等比缩放。

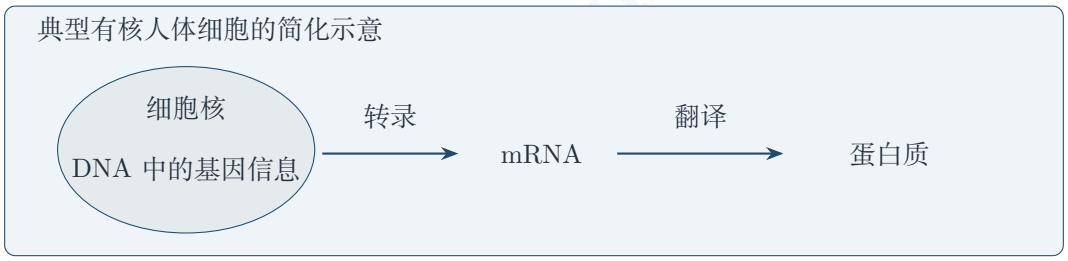
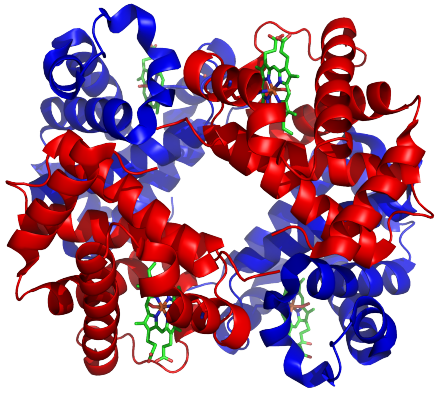


图 9 信息关系示意，不按实际尺寸绘制。mRNA 在核内产生，参与蛋白质制造前通常需要加工并转运；图中省略这些步骤。部分 RNA 本身有功能，不进入翻译路线。



把功能名词与具体结构联系起来。血红蛋白是上文运输氧气的例子，这里可以看到蛋白质的空间结构。

再回到测量层次。RNA 提供表达线索；若要判断蛋白质含量或功能是否发生变化，仍需相应证据。

图 10 血红蛋白的三维结构模型，由 PDB 1GZX 的结构数据绘制，飘带帮助展示蛋白链的折叠。模型不是显微照片，绘图颜色也不是分子的真实颜色；它不能给出组织中的蛋白质含量。

图片：Richard Wheeler (Zephyris)；许可：CC BY-SA 3.0；原图等比缩放。

5 基因表达是在说什么

5.1 表达表示基因信息被用于产生功能产物

基因表达（gene expression），是基因信息被用于产生 RNA 或蛋白质等功能产物的过程。研究 RNA 数据时，“某基因表达高”通常表示与这个基因相关的 RNA 信号测得较多。[8]

例如，细胞甲和细胞乙都拥有某个基因，但在相同测量条件下，甲记录到更多对应 RNA。我们会说甲的这个基因表达较高。它并不表示甲拥有更多个基因，也不表示 DNA 序列变长了。

5.2 为什么相似 DNA 能产生不同细胞

细胞并不会同样程度地使用所有基因。不同的表达组合与细胞不同的结构、功能和状态有关。可以把它理解成：员工拥有相似的说明书，但当前执行的任务不同，生成的工作副本也不同。

5.3 细胞类型和细胞状态要分开

细胞类型（cell type）是较稳定的身份，例如免疫细胞中的 T 细胞；**细胞状态**（cell state）是当下的活动情况，例如应对刺激或正在增殖。增殖就是细胞分裂、数量增加相关的过程。

同一种类型可以有不同状态，不同类型也可能共享一种状态。例如，多个类型都可能处于增殖状态。算法把细胞分成两组后，需要判断分组反映的是身份、状态，还是实验差异。

5.4 标志基因怎样帮助识别细胞

某些基因的表达常为识别细胞身份或状态提供线索，我们称它们为**标志基因**（marker gene）。科研人员通常结合多个标志、已有研究和组织背景判断，而不是看到一个基因较高就给出确定标签。

5.5 RNA 多为什么不一定等于蛋白质多

从 RNA 到蛋白质，中间还有翻译效率和蛋白质降解等过程。测 RNA 是一个观测层次，测蛋白质是另一个观测层次。RNA 数据可以提出功能相关假设，但不自动证明蛋白质数量或功能强度发生了相同变化。

理解检查

基因是信息区段，表达是信息被使用；细胞类型是身份，细胞状态是当下情况。空间转录组主要提供 RNA 层面的表达线索。请试着解释：两个细胞拥有相似的 DNA，为什么仍可能表现出不同的功能？

第二部分

测量原理与空间信息

第 6–9 章：从 RNA 集合到带位置的实验读数

这一部分要理解什么

理解转录组测量的范围和局限，比较混合组织、单细胞与空间测量。弄清一个测量单位代表什么，以及条形码、UMI 和成像怎样把 RNA 信号与位置关联起来。

Auutuumn

6 转录组是很多 RNA 的整体情况

6.1 先理解为什么要加一个“组”字

只测一个基因，可以看到一个信号；同时测很多基因，才能看到整体的表达组合。**转录组**（transcriptome）指一个细胞或组织在特定条件下的 RNA 集合。[9]

你可以把它理解为一份“当时的 RNA 情况表”。它与基因组不同：基因组主要描述保存的遗传信息，转录组描述当时存在的 RNA。细胞的环境或状态改变时，转录组也可能变化。

6.2 一个基因和一个 RNA 分子不是一一对应

一个基因可以产生很多 RNA 分子。一个基因也可能产生不同的**转录本**（transcript）。这里的转录本可以先理解为 RNA 产物；谈“转录本种类”时，也可能在区分同一基因产生的不同版本。

在常见入门分析中，研究人员会把与同一基因有关的信号汇总到基因层面。因此表达表的一列常是一个基因，数值反映该基因相关信号，而不是说“每个基因只有一个 RNA”。

6.3 测转录组不等于测到了所有 RNA

真实实验存在捕获效率、测序投入和技术覆盖范围的限制。有些方案关注较广的转录组，有些只检测预先选定的一组基因。这组目标叫 **panel**（基因面板），可以先理解为实验事先决定的“测量名单”。

因此，数据里没看到某个 RNA 信号，不能直接说细胞完全没有它。尤其某个基因根本不在测量名单中时，它属于没有观测，不能当成确定的零表达。

对 CS / AI 读者来说，这里要区分两种情况：“测了这个特征但读数为零”，以及“实验根本没有测这个特征”。即使文件里都能用零填充，它们的含义也不相同。

6.4 RNA 测量怎样帮助研究组织

假设免疫相关的一组基因在某些区域更明显，研究人员就有理由进一步检查这些区域是否含有免疫细胞。表达模式提供线索，已有参考和额外验证帮助判断线索是否可靠。

我们还没有加入空间。下一步先看看：如果同样测 RNA，但把细胞合在一起或分开测，会得到哪些不同信息。

本章要记住

转录组是一组 RNA 的整体情况；表达数据是对它的不完整测量。

7 混在一起测和分开测有什么区别

7.1 第一种方式是测一份混合组织

如果把一块组织中的 RNA 汇总来测，我们得到整份样本的总体表达情况。这类方法常叫 **bulk RNA-seq**，bulk 可以先理解为“混合在一起”。RNA-seq 指通过测序来研究 RNA。[10]

它像把公司的工作记录全部汇总：你能知道整个公司用了哪些任务信息，但很难区分每条记录来自哪个员工。某个信号变多，可能是相关员工变多，也可能是每个人的活动更强。

7.2 第二种方式是尽量分别测每个细胞

单细胞 RNA 测序，简称 **scRNA-seq**，尽量把不同细胞的 RNA 信号分开记录。于是可以比较不同细胞，发现它们有哪些身份和状态差异。常见实验需要将细胞从组织中**解离**，也就是从原来的结构里分离出来。

这像分别保存每个员工的工作记录，但通常丢失了他们原来的座位。并非所有细胞都能成功进入数据，一次记录也可能混入多个细胞，所以仍然需要质量检查。

研究方式	得到什么	暂时看不到什么
混合组织测量	整份组织的总体表达	每种细胞各自贡献多少
单细胞测量	分别记录细胞间的表达差异	常规解离后细胞原来的组织位置

7.3 单细胞核又是什么

一些实验分离并测量细胞核，称为**单细胞核 RNA 测序**，简称 **snRNA-seq**。细胞核是细胞的一部分，因此核内 RNA 与整个细胞 RNA 的构成不完全相同。现在只需知道：single-cell 和 single-nucleus 不是完全相同的测量对象。

7.4 我们的研究问题还缺什么

对肿瘤薄片，即使知道存在多少种免疫细胞，我们仍想知道它们在内部还是边缘、与哪些细胞相邻。仅有总体表达或失去原位坐标的单细胞表，都不能直接完整回答这个布局问题。

本章要记住

bulk 看总体，单细胞看个体差异；想研究组织布局，还要保留位置。

Auutuumn

8 空间转录组把表达放回组织地图

8.1 空间转录组同时关联表达和位置

空间转录组学（spatial transcriptomics），是在保留空间位置关联的条件下测量组织中的 RNA 表达。它让我们研究“哪些表达信号出现在哪里”，以及这些位置之间的关系。[11]

把公司类比补完整：我们有员工的工作记录，也保留座位图。研究对象由一份没有布局的信息表，变成了一张具有表达信息的组织地图。

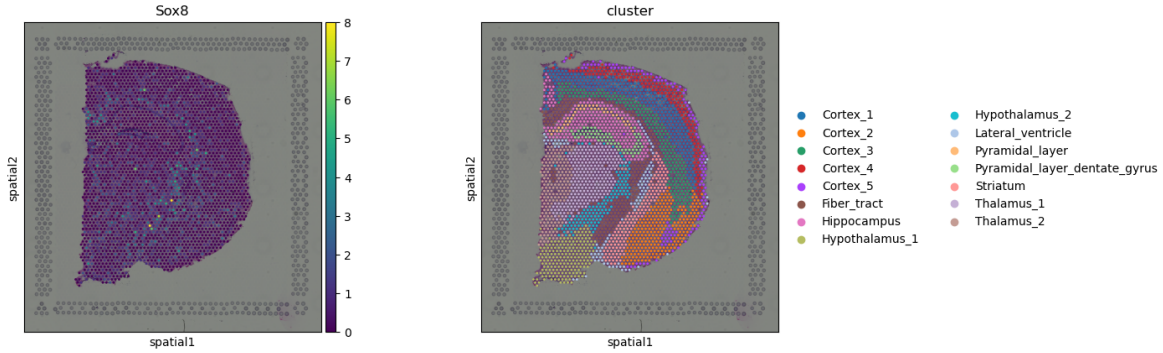


图 11 空间数据的真实可视化示例，来自 Squidpy 官方 Visium 教程。左图用连续颜色表示 Sox8 表达信号，右图用离散颜色显示分群及注释标签，两图使用同一组织的空间位置。圆点代表测量位置，不自动等于单个细胞；注释标签包含分析与解释，并非实验直接读出的身份。

图片：Squidpy / Theis Lab / scverse；许可：BSD 3-Clause；原图等比缩放。

8.2 为什么位置有生物学意义

组织的功能依赖细胞的排列与局部环境。免疫细胞集中在肿瘤边缘或出现在内部，是两个不同的观察；脑组织不同结构层的表达模式，也可能不同。位置帮助研究人员提出更具体的问题，但布局本身不直接证明某个功能或因果关系。

8.3 空间不意味着每一行都是一个细胞

不同技术的测量单位不同。有些数据对应分割得到的细胞，有些对应一个捕获区域。捕获区域常叫 **spot**，你可以先把它想成组织上的一个小圆圈或小区域，里面可能有多个细胞。

较细的网格也可能被合并成 **bin**，即一个用于分析的网格区域。无论它多小，网格边界都不自动等于细胞边界。一份数据到底是在测细胞、spot 还是 bin，要看实验和后续处理。

一行对应的对象	你能直接说什么	你还不能直接说什么
分割得到的细胞	该细胞区域记录到的 RNA	分割及分子归属完全正确
多细胞 spot	该区域的混合 RNA 信号	每个细胞分别表达多少
合并网格 bin	该网格区域的 RNA 信号	这个网格就是一个完整细胞

常见实验测量一张二维组织切片。二维坐标保留切片中的位置，不能直接代表完整器官的三维结构。研究三维组织时，通常还需要多个切片或其他信息。

本章要记住

转录组提供 RNA 表达信息，空间保留这些信息在组织中的位置；分析前先确认一个观测位置究竟代表什么。

9 实验怎样知道哪些 RNA 来自哪里

9.1 先看一种典型的测序路线

下面以捕获 RNA 的空间条形码方案为例。研究人员准备一张载体，上面不同捕获位置带有不同的条形码序列。**条形码**（barcode）可以先理解成位置标签；实验知道每个标签对应哪个位置。

将组织薄片放在载体上，捕获到的 RNA 经实验处理获得相关标签，再进行测序。测序仪读到的序列片段叫 **read**。计算流程识别标签以及目标基因，便能把分子信号关联回位置。2016 年的经典空间转录组工作采用了这一类思路。[11]

9.2 一份读数要回答两个问题

问题	帮助回答的信息	通俗理解
来自哪里	空间条形码和对应坐标	包裹上的地址标签
属于哪个目标	RNA 对应的序列或探针信息	包裹内容的识别线索

实验常将 RNA 的信息转换到适合建库和测序的 DNA 产物上，再测序；这不改变我们研究的对象是 RNA 表达。这里省略实验化学细节，但要避免把“测序仪读到 DNA 产物”误解为“正在研究基因组突变”。[10]

这里的**建库**，可以先理解为把分子处理成测序仪可以读取的一组材料；它不是建立计算机数据库。

9.3 为什么多个 reads 不一定等于多个 RNA

建库中的扩增可能让一个原始分子产生多个副本，因此多个 reads 可能来源相同。部分方案加入 **UMI**（unique molecular identifier，独特分子标识符），帮助识别重复来源。可以把空间条形码理解为“位置标签”，把 UMI 理解为“分子去重线索”。[12]

例如，在同一位置、同一基因下，若若干 reads 具有相同的 UMI，流程可能把它们合并为一个分子来源的计数。真实去重还涉及序列错误等问题，因此这个例子只说明“reads 数量”和“去重后的分子计数”为何可能不同。

9.4 另一条路线是直接在组织里成像

成像型方法使用探针等分子工具识别目标，并通过显微成像及多轮识别等过程定位 RNA。**探针**可以先理解为实验中识别特定目标的工具。它可能输出“某种 RNA 在坐标哪里”的分子表，再聚合到细胞或区域。[13]

本章要记住

先理解两条思路：通过标签保留位置，或通过成像定位分子。不同方案能检测什么、测得多细、测得多完整，会影响后续计算问题。现在不用背平台名。

第三部分

计算分析与科研实践

第 10–15 章：从表达矩阵到可信科学结论

这一部分要理解什么

把实验读数转成矩阵、坐标与图像，理解常见分析步骤及算法任务。沿着肿瘤切片的例子，分清测量、推断、比较和验证，学习判断模型输出能支持怎样的结论。

Auutuumn

10 从 RNA 读数到 CS 的矩阵

10.1 把同一位置、同一基因的信号汇总

完成识别和计数后，我们可以为每个位置列出：与基因 A 相关的信号多少，与基因 B 相关的信号多少，依此类推。这就得到**基因表达矩阵**（gene expression matrix）。

位置	基因 A	基因 B	基因 C
P1	30	2	5
P2	27	3	8
P3	3	28	4
P4	16	17	6

这是教学计数，不是真实数据。A、B、C 也不是实际基因名。假设 A 为上皮相关表达提供线索，B 为免疫相关表达提供线索，C 与某种增殖相关表达有关；真实注释需要多个标志和其他证据。

10.2 一行、一列、一个数字各是什么

一行对应一个位置，在别的数据中也可能对应一个细胞。一列对应一个基因。P1 行、A 列的 30，表示实验在 P1 对基因 A 记录的计数为 30；它不是 P1 有 30 个基因 A，也不一定是精确无误的 30 个真实 RNA 分子。

用 CS 符号写，原始计数矩阵可以表示为

$$X \in \mathbb{N}_0^{N\times G}, \qquad X_{ig} = \text{第 } i \text{ 个观测单位对第 } g \text{ 个基因记录到的计数.}$$

这里 N 是观测位置数，G 是基因数，$\mathbb{N}_0$ 表示包含零的非负整数集合。教学例子中 $N = 4$、$G = 3$，每一行都可以看作一个三维特征向量。

归一化或其他变换后，矩阵一般写作 $X \in \mathbb{R}^{N\times G}$，数值可以变成小数，甚至在某些表示中有负值。**先确认数据状态，再解释数字**。另外，有些文件把基因放在行、位置放在列；本文统一采用“观测 × 基因”的方向。

10.3 这样就能开始读表达模式

P1 和 P2 的 A 较高，P3 的 B 较高，P4 同时有 A 与 B。若 P4 是多细胞 spot，一个合理假设是它混合了不同类型的细胞。但如果它对应单个细胞，就还要考虑真实共表达、分割或背景问题。

10.4 矩阵里的零该怎样理解

零首先表示这个流程没有记录到对应信号。实际表达低、捕获不到或测序不足，都可能导致零。因此不能把全部零都认定为生物学上的不存在，也不能假设它们全部都是应当补齐的缺失。

理解检查

矩阵一行是测量单位，一列是基因，数值是实验读数或处理后的表达值。请试着解释：为什么 P4 的读数不能直接证明“一个细胞同时具有两种身份”？

11 坐标、图像和文件怎样与矩阵对应

11.1 表达矩阵之外还要有坐标

对四个位置，我们可以另外保存

$$P1 = (0, 0), \quad P2 = (1, 0), \quad P3 = (0, 1), \quad P4 = (1, 1).$$

这张坐标表与表达表用同一组位置 ID 对应。ID 可以先理解为数据库里关联两张表的键。二维坐标可以写成 $S \in \mathbb{R}^{N\times 2}$；$S$ 的第 i 行和 X 的第 i 行必须对应同一个观测单位。实际操作中，应检查 ID 的对应关系，不能只凭两个数组的行数相同就直接拼接。

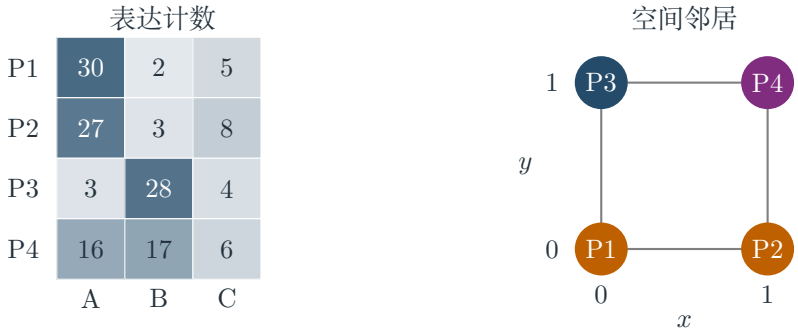


图 12 教学示意。左边看表达，右边看位置；连线表示横向或纵向相邻。颜色只是帮助区分表达特征，不是经过验证的细胞类型标签。

11.2 表达相似和位置相邻是两种关系

P1 与 P2 的表达模式较相似；P1 与 P3 在空间上相邻，却可能有明显不同的表达。前者研究“分子特征像不像”，后者研究“在组织里近不近”。后面遇到表达邻居和空间邻居时，就用这个例子区分。

11.3 组织图像是第三类信息

图像显示形态与结构，坐标告诉你表达位置落在图像的哪里。把两者对齐叫**配准**(registration)。如果缩放、方向或坐标单位错了，一个真实表达信号就可能被画到错误的区域。图像像素和物理微米也不是同一种单位。

11.4 AnnData 和 H5AD 只是数据容器与格式

AnnData 是常见的带注释矩阵对象；H5AD 是它的常见保存格式。你可以先把它理解成“矩阵 + 关联表 + 附加数组”的一个文件包。[14]

字段	常见用途
`X`	工作矩阵，通常为观测 × 基因
`obs`	每行观测的元数据，例如样本 ID、质量指标、注释
`var`	基因信息，例如基因名称
`obsm`	与观测对应的附加数组，可存坐标或低维表示
`layers`	相同形状、不同处理状态的表达矩阵

文件叫 H5AD，不代表它已经做完质量控制；字段叫 `raw`，也不保证里面就是原始计数。应以数据说明和处理记录为准。

12 常见分析步骤分别为了什么

12.1 首先确认你拿到的是可靠输入

质量控制（quality control，QC），是检查哪些观测可能有问题。例如某位置总计数极低，可能是没覆盖到组织，也可能是这里细胞本来少。QC 不是套一组统一阈值；要结合组织图像、平台和实验背景解释。

对原始计数矩阵，一个直观的检查量是第 i 个位置的总计数

$$L_i = \sum_{g=1}^{G} X_{ig}.$$

L_i 大，表示记录到的总信号多；它本身不能区分“细胞更多”“每个细胞 RNA 更多”和“测量效率更高”等原因。

12.2 再处理数值尺度并找到表达模式

归一化（normalization）调整数值尺度，缓解部分测量总量差异；常见 `log1p` 变换计算 $\log(1+x)$，压缩特别大的数值。它们不能恢复未捕获分子，也不保证消除所有技术误差。不同模型要求的输入状态不同。[15]

例如，一种按总量缩放再取对数的处理方式是

$$\widetilde{X}_{ig} = \frac{X_{ig}}{L_i}\, c, \qquad Z_{ig} = \log\bigl(1 + \widetilde{X}_{ig}\bigr), \quad L_i > 0,$$

其中 c 是人为选择的统一尺度。这个式子只是帮助你读懂一种常见操作，不是所有平台和模型的统一配方。$L_i = 0$ 的观测需要先单独处理，也不能把 Z 当作原始计数输入所有模型。

很多基因同时进入分析时，研究人员可能先选择较有信息的基因，再降维。**降维**就是用更少的数值保留重要差异，PCA 是一种常用方法。**高变基因**（highly variable genes，HVG）是根据变异特征选出的一类候选基因；它不等于“最重要的致病基因”。

12.3 聚类是发现群体，注释是解释群体

聚类（clustering）把表达较相似的观测分组；**注释**（annotation）则综合标志基因、参考数据和组织背景，解释这些组可能是什么。聚类编号 0、1、2 本身没有生物身份。

步骤	直白解释	一个需要追问的问题
QC	读数是否值得信任	低信号是质量问题还是组织特点
归一化	让部分尺度差异更可比	会不会改变想研究的总量差异
降维与聚类	找出主要差异并分组	分组来自类型、状态还是批次
注释	为群体给出生物解释	有哪些标志和参考支持
空间分析	将表达模式放回组织	区域、邻居和边界有什么意义

这里的**批次**是不同实验轮次、处理条件等带来的分组；批次差异可能与想研究的生物差异混在一起。

12.4 为什么 UMAP 图不是组织地图

UMAP 常把高维表达映射到二维，用于展示某些表达关系。图上的横纵坐标是算法产生的，不是细胞在组织里的真实坐标。表达图上靠近的点，可能在组织里很远。想看组织布局，要画真实空间坐标。

如果遇到 Scanpy，它是常见表达分析工具；Squidpy 增加空间图与空间统计等能力。先知道工具各自的用途，再学习具体函数。[15, 16]

本章要记住

每一步都有要解决的测量或分析问题；一套流程跑通，并不自动意味着分组有生物学意义。

13 算法能够研究哪些问题

13.1 问题一：组织里有哪些不同区域

研究人员想找出结构或表达不同的区域，例如某些组织层、肿瘤内部或边缘。这样的区域叫**空间域**（spatial domain）。一种区域可以包含多类细胞，同一种细胞也可以出现在多个区域。

从 CS 看，这涉及聚类、表征学习或分割。但空间相邻的点不一定同类，模型过度平滑可能把真实边界抹掉。空间域标签回答的是“这里属于什么区域”，不一定回答“这里的细胞是什么类型”。

13.2 问题二：混合区域里有什么细胞

一个 spot 中含有多种细胞时，测到的是混合表达。**反卷积**（deconvolution），就是尝试从混合信号推断各类成分。它类似已知不同乐器的大致音色，再分析一段混合声音里各自的贡献。

一些方法使用单细胞数据作为参考，相当于提供不同细胞类型的表达模板，再推断空间位置的组成。输出可能是类型丰度、相对贡献或比例，要按方法定义解释；RNA 贡献比例不自动等于细胞数量比例。cell2location 是相关方法的一个例子。[17]

13.3 问题三：能否从图像预测表达

给模型一个组织图像块，让它输出一组基因的表达值，这可以看作多输出回归或多模态学习。它利用形态与表达之间的统计关联；预测结果仍是推断，不能当作新完成的 RNA 实验。

13.4 问题四：哪些信号在空间上变化

研究人员会寻找与位置有关的表达模式，例如某个信号在某个区域更明显。这样的基因可称为**空间变异基因**（spatially variable genes，SVG）。表达变化很大却分布随机，与呈现有组织的空间梯度，是不同现象。

13.5 问题五：哪些细胞可能相互影响

细胞可以通过分子信号相互影响。**配体**（ligand）是与受体结合的信号分子等；**受体**（receptor）是接收相关信号的分子组件。算法结合表达、空间关系和已有配体受体知识，提出候选通信关系。CellChat 是相关推断框架的一个例子。[18]

空间靠近或 RNA 共表达都不是通信发生的完整证明。需要进一步研究对应蛋白质、下游变化或实验干预。CS 在这里帮助提出和检验假设，而不是只输出一张漂亮的网络。

本章要记住

先把生物问题翻译成明确的输入与输出，再选择算法。区域、细胞组成、预测表达和候选通信关系是不同的输出。

14 用一个问题串起科研全过程

14.1 从问题开始，而不是从模型开始

贯穿全文的问题是：**这张肿瘤组织切片中的免疫细胞主要在哪里？**为了回答它，先明确实验记录的是单个细胞还是混合 spot，并确认哪些表达信号和参考数据能帮助识别免疫细胞。

14.2 第一步：分清观察与推断

实验直接提供的是记录到的分子信号与对应位置。若有组织图像，它还提供形态信息。“这个位置含有多少免疫细胞”通常还需要注释或反卷积，属于基于观测的推断。

14.3 第二步：定义你要比较的区域

肿瘤内部与边缘怎样确定？可能来自专家对图像的标注，也可能来自其他有依据的分析。必须说明区域定义，否则“更多在内部”没有明确的比较对象。标注是参照信息，但也可能存在不确定性。

14.4 第三步：选择与测量单位相符的方法

单细胞数据可以在有依据的注释后统计不同区域的细胞分布。混合 spot 数据需要意识到区域内可能包含多种细胞，必要时推断类型丰度，不能强制把整个 spot 都判成单一细胞身份。

14.5 第四步：看结果是否真的支持描述

把结果画回组织，检查是否与图像和标志表达相符；同时比较数量、密度或丰度等明确指标。内部面积大时，单纯看总数量可能产生误导。因此要提前定义“更多”是总数更多、单位面积更多，还是组成比例更高。

例如，对可以按细胞计数的数据，设区域 r 中免疫细胞数为 $n_{\text{immune},r}$，区域面积为 A_r，区域内总细胞数为 $n_{\text{all},r}$，则

$$\text{免疫细胞密度} = \frac{n_{\text{immune},r}}{A_r}, \qquad \text{免疫细胞比例} = \frac{n_{\text{immune},r}}{n_{\text{all},r}}.$$

两者分别回答“单位面积有多少”和“细胞中占多少”。分母须大于零；若方法只输出相对 RNA 贡献，就不能直接把它当成这里的细胞数。

14.6 第五步：决定能把结论说到哪里

在这一张切片上看到了某种分布，可以形成针对这份样本的观察。如果要推广到一类患者，则需要更多独立供体和合适的实验设计。如果要解释分布为何形成，还需要机制或干预证据。

阶段	一句话表述
测量	这个位置记录到哪些 RNA 信号
推断	这些信号可能由哪些细胞产生
比较	不同区域的分布是否有明确差异
验证	额外证据和独立样本是否支持这个结果
解释	什么机制可能造成差异，仍需哪些实验

本章要记住

进入科研后，不只问模型能做什么，还要问输入是什么证据、输出是什么假设，以及怎样验证它。

15 从 CS 模型到可信科学结论

15.1 大量位置不等于大量独立患者

一名患者的一张切片可以产生数千个位置，但这些位置共享供体和局部环境。数千个 spot 不能当作数千名患者。模型评估和统计推断都要明确独立样本单位。**供体**就是提供组织样本的个体。

15.2 训练、测试怎样分，取决于想验证什么

随机拆同一张切片的相邻位置，可以研究同一切片内的插值能力，但不能直接证明模型对新患者泛化。如果目标是新患者，通常应按供体划分；如果目标是新切片，就需要说明切片与供体之间的关系。

例如，同一患者的两张切片分属训练集和测试集，仍不能把这个设置称为对“未见患者”的测试。划分单位应与想宣称的泛化范围一致。

特征选择、参考构建或参数调节如果用到了测试数据，也要说明。允许使用无标签目标数据的设置，与完全不见目标数据的泛化设置，回答的不是同一个问题。

15.3 已有算法结果未必就是地面真值

Ground truth 常译为真值，实际研究中的参照可能是专家区域标注、独立实测，也可能是某个已有算法的输出。它们的证据强度不同。一个模型更像已有模型，不必然表示它更接近真实生物状态。

15.4 差异表达不直接证明原因

比较两组时发现某个基因表达不同，称为**差异表达**。它可以提示值得研究的现象，但差异可能来自细胞组成、状态、测量方式等。**FDR**（false discovery rate，假发现率）用于控制大量检验中的假发现问题；它不代替差异幅度和生物学解释，也不应直接解释为某一项具体结论为假的概率。

如果提出“某个基因导致了某种现象”，通常需要比相关性更强的证据，例如合适的干预实验。仅凭观察数据，表述应停留在数据实际支持的范围内。

15.5 读论文时先回答五个问题

1. 研究的是哪种组织，想回答什么生物问题？
2. 一行是什么，表达值是怎样得到的？
3. 模型输出是直接观测，还是推断结果？
4. 用什么参照和独立数据验证？
5. 比简单方法多解决了哪个具体困难？

理解检查

空间转录组把表达与位置关联；算法帮助组织和推断信息；生物结论仍需要与问题相匹配的验证。现在请从“组织薄片”开始，依次讲清测量、矩阵、位置、算法输出和验证之间的关系。

第四部分

术语回查与延伸阅读

第 16–17 章：回到概念，继续学习

这一部分要理解什么

用术语表回查前文的概念与常见混淆，再按学习进度阅读基础名词、数据对象与分析工具文档。无需一次记住所有术语。

Auutuumn

16 核心术语回查

16.1 如何使用这份术语表

这一章用于回查，不需要背诵。先用左侧术语找到前文已经建立的直觉，再按具体论文或实验补充细节。

16.2 核心术语与常见混淆

术语	最初的理解	容易混淆的地方
细胞 Cell	组织里的基本结构与功能单位	不是每个空间观测都等于一个细胞
组织 Tissue	细胞与周围材料形成的结构	组织含有布局与结构关系
DNA	保存遗传信息的分子	DNA 不会因为转录而全部变成 RNA
基因 Gene	DNA 上具有功能的特定区段	基因存在不等于当前高表达
RNA 与 mRNA	RNA 是一类分子，mRNA 是其中一种	部分 RNA 不被翻译成蛋白质
蛋白质 Protein	氨基酸链形成的功能分子	RNA 数量不直接等于蛋白质数量
转录与翻译	制造 RNA 与按 mRNA 制造蛋白质	两者是不同步骤
基因组与转录组	遗传信息与当时的 RNA 集合	保存的信息与表达状态不同
转录本 Transcript	转录产生的 RNA 产物	同一基因可能有不同版本的产物
基因表达	基因信息被用于产生功能产物	RNA 数据中常指相关 RNA 信号水平
细胞类型与状态	相对稳定的身份与当前活动情况	一个聚类可能反映类型或状态
标志基因 Marker	帮助识别身份或状态的表达线索	一个标志通常不够确证身份
Panel	预先选定的测量基因名单	不在名单中不等于零表达
Bulk 与 scRNA-seq	混合组织与单细胞的 RNA 测量	测量总体与区分个体是不同层次
Spot 与 bin	捕获区域与合并网格区域	区域边界不自动等于细胞边界
Barcode 与 UMI	位置等标签与分子去重线索	UMI 不用于标注细胞类型
Read 与 count	序列读段与流程汇总后的计数	扩增可使多个 reads 来自同一分子
Counts 与归一化值	计数与经过尺度处理的数值	必须按数据状态解释
配准 Registration	将坐标与图像等信息对齐	单位、缩放和方向错误会造成错位
AnnData 与 H5AD	数据对象与常见文件格式	文件格式不能保证处理质量
聚类与注释	算法分组与生物学解释	编号没有自带身份标签
UMAP 与空间坐标	表达的低维表示与实际组织位置	UMAP 图不是组织地图
空间域与反卷积	找组织区域与拆解混合表达	区域标签与细胞组成是不同输出
HVG 与 SVG	表达变异信息与空间变化信息	变异大不一定有空间规律
配体与受体	参与信号传递的分子与接收组件	通信候选仍需要验证
供体 Donor	提供组织样本的个体	很多位置不等于很多独立供体

17 来源和下一步阅读

17.1 按学习进度安排下一步阅读

先读 NHGRI 的基础名词页面，再用本文的矩阵例子理解数据。理解到第 11 章后，可以读 AnnData 文档；理解到第 12 章后，再看 Scanpy 与 Squidpy 的基础示例。暂时不必先啃复杂算法论文。

面向本科生，可以先做到能解释术语、读懂矩阵和区分观察与推断；面向准备进入科研的研究生，再重点检查测量单位、数据处理状态、独立样本与验证设计。两条路径沿用同一条理解主线。

17.2 参考来源

下列 18 项来源沿用原 PDF 的编号与链接。工具文档页面可能随版本更新，实际使用时应结合所用版本阅读。

[1] National Cancer Institute (NCI). *Organ*：器官与组织层次. https://www.cancer.gov/publications/dictionaries/cancer-terms/def/organ

[2] National Human Genome Research Institute (NHGRI). *Deoxyribonucleic Acid (DNA)*：*DNA* 的结构与信息. https://www.genome.gov/genetics-glossary/Deoxyribonucleic-Acid-DNA

[3] NHGRI. *Talking Glossary*：基因、染色体、基因组等基础术语. https://www.genome.gov/genetics-glossary

[4] NHGRI. *Transcription*：转录. https://www.genome.gov/genetics-glossary/Transcription

[5] NHGRI. *Messenger RNA (mRNA)*：信使 *RNA*. https://www.genome.gov/genetics-glossary/Messenger-RNA-mRNA

[6] NHGRI. *Protein*：蛋白质. https://www.genome.gov/genetics-glossary/Protein

[7] NHGRI. *Translation*：翻译. https://www.genome.gov/genetics-glossary/Translation

[8] NHGRI. *Gene Expression*：基因表达. https://www.genome.gov/genetics-glossary/Gene-Expression

[9] NHGRI. *Transcriptome Fact Sheet*：转录组. https://www.genome.gov/about-genomics/fact-sheets/Transcriptome-Fact-Sheet

[10] NHGRI. *RNA-seq*：*RNA* 测序的基本原理. https://www.genome.gov/genetics-glossary/RNA-seq

[11] Ståhl 等，2016. *Visualization and analysis of gene expression in tissue sections by spatial transcriptomics. Science.* 空间转录组原始研究。https://www.science.org/doi/10.1126/science.aaf2403

[12] 10x Genomics. *Glossary of Terms*：*UMI* 等实验术语. https://www.10xgenomics.com/support/cn/software/cell-ranger-arc/latest/getting-started/glossary-of-terms

[13] 10x Genomics. *Spatial Transcriptomics*：空间 *RNA* 检测技术示例. https://www.10xgenomics.com/spatial-transcriptomics

[14] AnnData 文档. *AnnData API*：数据对象及字段. https://anndata.readthedocs.io/en/stable/generated/anndata.AnnData.html

[15] Scanpy 文档. *Clustering*：预处理与聚类基础流程. https://scanpy.readthedocs.io/en/stable/tutorials/basics/clustering.html

[16] Palla 等，2022. *Squidpy: a scalable framework for spatial omics analysis. Nature Methods.* 空间分析框架。https://www.nature.com/articles/s41592-021-01358-2

[17] Kleshchevnikov 等，2022. *Cell2location maps fine-grained cell types in spatial transcriptomics. Nature Biotechnology.* 反卷积方法示例。https://www.nature.com/articles/s41587-021-01139-4

[18] Jin 等，2021. *Inference and analysis of cell-cell communication using CellChat. Nature Communications.* 通信推断方法示例。https://www.nature.com/articles/s41467-021-21246-9